

**Terceira Semana - First Challenge****Dicionário de Features para Classificação de Golpes*****Integrantes:****Alvaro Santos de Almeida**Bruno Henrique de Almeida Lima**Lucas Soares Gonçalves**Leonid H. Mamani**Maria Clara Rodrigues da Silva**Vicente Matheus Collin Pedroso***2026****Campinas****1. solicita\_senha**

## **DEFINIÇÃO**

A mensagem possui esta feature quando solicita explicitamente que o destinatário informe, envie, digite, confirme, atualize ou compartilhe uma senha de acesso.

## **CRITÉRIOS DE CLASSIFICAÇÃO**

Deve existir referência a senha e uma ação dirigida ao usuário envolvendo essa senha.

### **Exemplos válidos:**

"Informe sua senha." ;

"Digite sua senha para continuar." ;

"Envie sua senha para confirmar sua identidade."

### **Não considerar:**

"Nunca compartilhe sua senha." ;

"Sua senha foi alterada." ;

"Esqueceu sua senha?"

## **EXEMPLO**

"Para confirmar seu cadastro, informe sua senha de acesso no formulário abaixo."

## **AUTOMAÇÃO / OBSERVAÇÕES**

Regex pode procurar a palavra "senha", mas a decisão deve considerar também os verbos de solicitação. Uma simples "senha existe no texto" gera falsos positivos.

A feature é relativamente objetiva e pode ser automatizada com regras + análise contextual simples.

## **2.solicita\_codigo\_autenticacao**

## **DEFINIÇÃO**

A mensagem possui esta feature quando solicita explicitamente um código utilizado para autenticação, confirmação ou verificação de identidade, incluindo códigos de SMS, WhatsApp, autenticação em dois fatores, token ou código de segurança.

## **CRITÉRIOS DE CLASSIFICAÇÃO**

- Deve haver referência a código/token de autenticação.
- Deve existir solicitação para informar, enviar, digitar ou compartilhar esse código.
- Não considerar apenas o aviso de que um código será enviado.

## **EXEMPLO**

“Digite aqui o código de 6 números que você recebeu por SMS para confirmar sua conta.”

## **AUTOMAÇÃO / OBSERVAÇÕES**

Pode ser identificada com combinação de palavras-chave como “código”, “token”, “verificação” e verbos de solicitação. A simples presença da palavra “código” não é suficiente.

## **3.solicita\_dados\_bancarios**

## **DEFINIÇÃO**

A mensagem possui esta feature quando solicita informações usadas para identificar ou acessar uma conta bancária ou realizar operações bancárias.

## **CRITÉRIOS DE CLASSIFICAÇÃO**

Considerar número da conta, agência, banco, dados de conta e outras informações necessárias para uma operação bancária. Dados de cartão devem ser tratados pela feature solicita\_dados\_cartao.

## **EXEMPLO**

“Para liberar seu benefício, informe o número do banco, agência e conta.”

## **AUTOMAÇÃO / OBSERVAÇÕES**

Pode começar com regras e expressões regulares, complementadas por análise de contexto. A solicitação precisa estar direcionada ao destinatário; apenas mencionar banco ou conta não basta.

## **4.solicita\_dados\_pessoais**

## **DEFINIÇÃO**

A mensagem possui esta feature quando solicita explicitamente informações pessoais que identificam ou descrevem o destinatário.

## **CRITÉRIOS DE CLASSIFICAÇÃO**

Considerar CPF, RG, nome completo, data de nascimento, endereço, telefone, e-mail e outros dados cadastrais. A simples menção a um dado pessoal não é suficiente.

## **EXEMPLO**

“Para atualizar seu cadastro, informe seu CPF, nome completo e data de nascimento.”

## **AUTOMAÇÃO / OBSERVAÇÕES**

Pode utilizar dicionário de termos + verbos de solicitação. Deve-se evitar marcar mensagens que apenas mencionam dados pessoais sem pedir que o usuário os forneça.

## **5.solicita\_dados\_cartao**

## **DEFINIÇÃO**

A mensagem possui esta feature quando solicita informações do cartão de pagamento, como número do cartão, validade, CVV/CVC, código de segurança ou nome impresso no cartão.

## **CRITÉRIOS DE CLASSIFICAÇÃO**

A simples menção a “cartão” não é suficiente. Deve existir pedido para fornecer ou informar os dados do cartão.

## **EXEMPLO**

“Para receber o reembolso, informe o número do cartão, validade e código de segurança.”

## **AUTOMAÇÃO / OBSERVAÇÕES**

Pode ser automatizada por regras. É potencialmente relacionada a solicita\_dados\_bancarios, portanto vale testar a redundância entre as duas no modelo.

## **6.solicita\_atualizacao\_cadastro**

### **DEFINIÇÃO**

A mensagem possui esta feature quando solicita explicitamente que o destinatário atualize, confirme, regularize ou complete seus dados cadastrais.

### **CRITÉRIOS DE CLASSIFICAÇÃO**

Considerar expressões como: "atualizar cadastro", "atualizar dados", "confirmar cadastro", "regularizar cadastro" e "validar dados cadastrais".

Não basta mencionar a palavra cadastro.

### **EXEMPLO**

"Seu cadastro está desatualizado. Acesse o link abaixo para confirmar seus dados."

### **AUTOMAÇÃO / OBSERVAÇÕES**

É adequada para regras baseadas em palavras e padrões de ação. Pode apresentar forte sobreposição com solicita\_dados\_pessoais.

## **7.solicita\_pagamento**

### **DEFINIÇÃO**

A mensagem possui esta feature quando solicita que o destinatário realize uma ação financeira, como pagar, transferir dinheiro, quitar uma cobrança, realizar depósito ou fazer PIX.

### **CRITÉRIOS DE CLASSIFICAÇÃO**

A simples menção a dinheiro ou pagamento não é suficiente. Deve existir uma ação financeira solicitada ao destinatário.

### **EXEMPLO**

“Para evitar o cancelamento do pedido, faça o pagamento de R\$ 29,90 ainda hoje.”

### **AUTOMAÇÃO / OBSERVAÇÕES**

Pode usar palavras-chave e expressões de ação. Pode haver forte relação com possui\_pix quando o pagamento é realizado por PIX.

## **8.solicita\_clique**

### **DEFINIÇÃO**

A mensagem possui esta feature quando instrui explicitamente o destinatário a clicar, acessar ou tocar em um link, botão ou endereço fornecido na própria mensagem.

### **CRITÉRIOS DE CLASSIFICAÇÃO**

Considerar “Clique aqui”, “Acesse o link”, “Toque neste endereço” e “Clique para confirmar”.

A presença de uma URL, sozinha, não implica solicita\_clique.

### **EXEMPLO**

“Clique no link abaixo para atualizar seu cadastro imediatamente.”

### **AUTOMAÇÃO / OBSERVAÇÕES**

Pode ser automatizada com dicionário de verbos e padrões de URL. Deve ser mantida separada de possui\_url.

## **9.solicita\_ligacao**

### **DEFINIÇÃO**

A mensagem possui esta feature quando instrui ou pede que o destinatário realize uma ligação telefônica.

### **CRITÉRIOS DE CLASSIFICAÇÃO**

Considerar “Ligue para 0800...”, “Entre em contato pelo telefone...” e “Ligue imediatamente”.

A simples presença de telefone não é suficiente.

### **EXEMPLO**

“Para confirmar o cancelamento, ligue imediatamente para 0800 123 4567.”

### **AUTOMAÇÃO / OBSERVAÇÕES**

Pode combinar padrões telefônicos com verbos como “ligue”, “telefone”, “entre em contato” e “chame”.

## **10.menciona\_bloqueio\_conta**

### **DEFINIÇÃO**

A mensagem possui esta feature quando afirma que uma conta, cartão, cadastro ou serviço será, está ou foi bloqueado, suspenso ou cancelado, ou quando apresenta uma ameaça explícita desse tipo.

### **CRITÉRIOS DE CLASSIFICAÇÃO**

O foco deve ser bloqueio, suspensão ou cancelamento de uma conta/serviço. Exemplos: "conta será bloqueada", "acesso será suspenso", "cartão será bloqueado" e "serviço será cancelado".

### **EXEMPLO**

"Sua conta será bloqueada hoje caso você não confirme seus dados."

### **AUTOMAÇÃO / OBSERVAÇÕES**

Pode usar regras de palavras-chave e contexto. Possui sobreposição importante com possui\_ameaca e possui\_urgencia.

## **11.carga\_emocional**

### **DEFINIÇÃO**

Esta feature não deve ser baseada apenas em interpretação humana livre. A proposta é tratá-la como uma medida linguística calculada.

Uma definição operacional possível é: carga emocional = proporção de palavras da mensagem identificadas por um léxico/dicionário linguístico como relacionadas a emoções em relação ao número total de palavras analisáveis.

### **CRITÉRIOS DE CLASSIFICAÇÃO**

Exemplo de cálculo: 6 palavras emocionais em 40 palavras analisáveis resulta em 0,15. O dicionário ou ferramenta utilizada deve ser fixado para todo o dataset.

Os valores podem posteriormente ser agrupados em baixa, média e alta, mas os limites devem ser definidos por uma metodologia consistente, e não arbitrariamente.

### **EXEMPLO**

“URGENTE!!! Você pode perder todo o seu dinheiro! Resolva AGORA antes que seja tarde!!!”

### **AUTOMAÇÃO / OBSERVAÇÕES**

É uma das features mais abstratas. Pode ser analisada com léxicos e ferramentas linguísticas, incluindo abordagens semelhantes às discutidas no FakeCor-pusBr/LIWC. Recomenda-se preservar inicialmente o valor numérico em vez de apenas 0/1.

## **12.possui\_urgencia**

### **DEFINIÇÃO**

A mensagem possui esta feature quando exige ou incentiva que o destinatário aja dentro de um período curto ou imediatamente, explicitamente ou por prazo próximo.

### **CRITÉRIOS DE CLASSIFICAÇÃO**

Indicadores incluem “agora”, “imediatamente”, “hoje”, “em poucos minutos”, “última chance”, “não perca tempo” e prazos curtos.

### **EXEMPLO**

“Regularize sua conta imediatamente. Você tem somente até hoje.”

### **AUTOMAÇÃO / OBSERVAÇÕES**

É possível começar com regras/dicionários e depois comparar com classificação zero-shot ou LLM. Possui sobreposição com linguagem alarmista e ameaça, mas o critério específico é a pressão temporal.

## **13.possui\_ameaca**

### **DEFINIÇÃO**

A mensagem possui esta feature quando apresenta explicitamente uma con-sequência negativa caso o destinatário não realize determinada ação.

### **CRITÉRIOS DE CLASSIFICAÇÃO**

Deve existir uma relação semelhante a: "Não faça X → acontecerá Y". Consequências podem incluir bloqueio, suspensão, cancelamento, multa, perda de dinheiro, perda de benefício ou restrição de acesso.

### **EXEMPLO**

"Caso você não atualize seus dados hoje, sua conta será bloqueada."

### **AUTOMAÇÃO / OBSERVAÇÕES**

Pode ser uma das features com maior sobreposição com menciona\_bloqueio\_conta e possui\_urgencia.

## **14.possui\_linguagem\_alarmista**

### **DEFINIÇÃO**

A mensagem possui esta feature quando utiliza linguagem explicitamente destinada a causar preocupação, medo ou percepção de perigo, apresentando uma situação como grave, crítica ou iminente.

### **CRITÉRIOS DE CLASSIFICAÇÃO**

Exemplos de indicadores: "ATENÇÃO!", "ALERTA!", "RISCO IMEDIATO!", "SITUAÇÃO GRAVE!", "VOCÊ ESTÁ EM PERIGO!".

A existência de urgência não implica automaticamente linguagem alarmista.

### **EXEMPLO**

"☐ ALERTA MÁXIMO! Detectamos uma atividade suspeita em sua conta. Resolva imediatamente!"

### **AUTOMAÇÃO / OBSERVAÇÕES**

Pode usar padrões linguísticos, sinais de pontuação e vocabulário alarmista, mas ainda possui componente subjetivo. Deve ser validada antes de ser aplicada em todo o dataset.

## **15.possui\_recompensa**

### **DEFINIÇÃO**

A mensagem possui esta feature quando afirma que o destinatário ganhou, receberá ou pode receber um prêmio, recompensa, brinde ou benefício por ter sido selecionado/contatado.

### **CRITÉRIOS DE CLASSIFICAÇÃO**

Considerar prêmio, recompensa, brinde, bônus, presente, sorteio e mensagens como “você ganhou” ou “você foi selecionado”.

### **EXEMPLO**

“Parabéns! Seu número foi sorteado e você ganhou um prêmio de R\$ 5.000. Clique aqui para resgatar.”

### **AUTOMAÇÃO / OBSERVAÇÕES**

É uma feature relativamente simples de identificar com vocabulário e padrões semânticos. Possui possível sobreposição com possui\_vantagem\_inesperada.

## **16.possui\_reembolso**

### **DEFINIÇÃO**

A mensagem possui esta feature quando afirma que o destinatário tem direito a receber de volta dinheiro, crédito ou valor pago anteriormente, ou que existe um reembolso disponível.

### **CRITÉRIOS DE CLASSIFICAÇÃO**

Indicadores: reembolso, devolução de dinheiro, valor a receber, restituição e crédito disponível para recebimento.

### **EXEMPLO**

“Identificamos um reembolso de R\$ 350,00 disponível para você. Clique aqui para receber.”

### **AUTOMAÇÃO / OBSERVAÇÕES**

Pode ser identificada por palavras-chave e contexto. É potencialmente um caso específico de vantagem inesperada.

## **17.possui\_vantagem\_inesperada**

### **DEFINIÇÃO**

A mensagem possui esta feature quando promete ao destinatário algum benefício positivo inesperado que ele não estava esperando receber, especialmente dinheiro, desconto, crédito, benefício ou oportunidade exclusiva.

### **CRITÉRIOS DE CLASSIFICAÇÃO**

Considerar dinheiro liberado, benefício disponível, crédito inesperado, desconto extraordinário e oportunidade exclusiva.

### **EXEMPLO**

"Você foi selecionado para receber um benefício de R\$ 1.500 que já está disponível para saque."

### **AUTOMAÇÃO / OBSERVAÇÕES**

Possui forte sobreposição conceitual com recompensa, reembolso e oferta financeira. Deve ser avaliada quanto à utilidade independente.

## **18.possui\_oferta\_financeira**

### **DEFINIÇÃO**

A mensagem possui esta feature quando apresenta ao destinatário uma oferta relacionada a dinheiro, crédito, empréstimo, investimento ou ganho financeiro, normalmente com proposta de contratação ou adesão.

### **CRITÉRIOS DE CLASSIFICAÇÃO**

Considerar empréstimo, crédito liberado, financiamento, investimento, retorno financeiro e promessa de ganho financeiro.

### **EXEMPLO**

"Seu crédito de R\$ 20.000 foi pré-aprovado. Clique aqui para contratar agora."

### **AUTOMAÇÃO / OBSERVAÇÕES**

Não marcar apenas porque a palavra "dinheiro" aparece. Deve existir uma oferta/proposta financeira direcionada ao destinatário.

## **19.possui\_url**

### **DEFINIÇÃO**

A mensagem possui esta feature quando contém pelo menos uma URL reconhecível, como `'https://site.com'`, `'http://site.com'` ou `'www.site.com'`.

### **CRITÉRIOS DE CLASSIFICAÇÃO**

A decisão deve ser baseada no padrão estrutural da URL, e não em interpretação humana.

### **EXEMPLO**

"Acesse <https://exemplo.com/atualizar> para continuar."

### **AUTOMAÇÃO / OBSERVAÇÕES**

Excelente candidata para automação determinística com regex. Também é recomendável armazenar a quantidade de URLs encontradas. Possuir URL não significa que ela é maliciosa.

## **20.possui\_url\_encurtada**

### **DEFINIÇÃO**

A mensagem possui esta feature quando contém uma URL cujo domínio pertence a um serviço conhecido de encurtamento de URLs.

### **CRITÉRIOS DE CLASSIFICAÇÃO**

A lista de domínios deve ser fixa e reproduzível. Exemplos: bit.ly, tinyurl.com, t.co, is.gd e ow.ly. Não classificar qualquer URL curta como encurtada.

### **EXEMPLO**

“Clique aqui para acessar sua conta: <https://bit.ly/3ABCxyz>”

### **AUTOMAÇÃO / OBSERVAÇÕES**

Pode ser automatizada com regex + lista de domínios. Deve ser mantida separada de possui\_url.

## **21.possui\_telefone**

### **DEFINIÇÃO**

A mensagem possui esta feature quando contém uma sequência de caracteres que corresponda ao padrão de um número de telefone brasileiro.

### **CRITÉRIOS DE CLASSIFICAÇÃO**

Devem ser reconhecidos formatos como

- (19) 99999-9999
- 19 99999-9999
- +55 19 99999-9999

e formatos equivalentes sem espaços/traços.

Deve-se considerar a quantidade esperada de dígitos e evitar confusão com CPF, CEP, códigos, datas e valores monetários.

### **EXEMPLO**

“Entre em contato pelo telefone (19) 99999-1234.”

### **AUTOMAÇÃO / OBSERVAÇÕES**

Esta feature deve ser automatizada por regex/validação numérica, e não por IA generativa. Isso evita exatamente o problema de marcar `possui\_telefone = 1` quando a mensagem não contém telefone.

## **22.possui\_pix**

### **DEFINIÇÃO**

A mensagem possui esta feature quando contém referência explícita ao sistema de pagamento PIX.

### **CRITÉRIOS DE CLASSIFICAÇÃO**

Considerar "PIX", "Pix", "chave Pix", "pagamento via Pix" e "transferência via Pix". A simples presença de números não deve gerar a feature.

### **EXEMPLO**

"Para liberar seu pedido, faça um PIX de R\$ 35,00 para a chave abaixo."

### **AUTOMAÇÃO / OBSERVAÇÕES**

Muito adequada para regra textual simples. Pode aparecer junto de solicita\_pagamento, mas as duas representam informações diferentes: uma identifica PIX e a outra identifica a ação de pagar.

## **23.possui\_erros\_ortografia\_gramatica**

### **DEFINIÇÃO**

A mensagem possui esta feature quando contém pelo menos um erro ortográfico ou gramatical identificável por uma ferramenta ou conjunto de regras previamente definido.

### **CRITÉRIOS DE CLASSIFICAÇÃO**

A regra deve ser baseada em uma ferramenta/método fixo. Não usar apenas a impressão de que a mensagem “parece mal escrita”.

É interessante registrar também quantidade de erros e/ou taxa de erros por palavra, em vez de apenas 0/1.

### **EXEMPLO**

“Sua conta foi bloqueada por atividade suspeita. Atualize seus dados imediatamente.”

### **AUTOMAÇÃO / OBSERVAÇÕES**

Abreviações naturais de WhatsApp, emojis, gírias e ausência de pontuação não devem ser automaticamente consideradas erros. É uma feature que exige validação da ferramenta escolhida.

## **24.possui\_chamada\_acao**

### **DEFINIÇÃO**

A mensagem possui esta feature quando contém um comando explícito orientado ao destinatário para executar alguma ação.

### **CRITÉRIOS DE CLASSIFICAÇÃO**

Exemplos de ações: clicar, acessar, ligar, enviar, informar, responder, confirmar, atualizar, pagar, baixar e compartilhar.

A característica identifica a existência da ação solicitada, independentemente de qual seja.

### **EXEMPLO**

“Informe seu CPF e clique no botão abaixo para confirmar.”

### **AUTOMAÇÃO / OBSERVAÇÕES**

É uma boa candidata a regras baseadas em verbos e construções imperativas.

Existe sobreposição importante com solicita\_clique, solicita\_ligacao, solicita\_pagamento e outras features de solicitação.